

정확도는 모델이 아니라, 설계에서 나옵니다.

aisight SRL 기술 소개서 - 스킬 기반 아키텍처와 지식 그래프, 시맨틱 추론 레이어(SRL)의 설계를 다룹니다.
질문의 의도를 확정하고, 근거 있는 답만 내보내는 구조를 소개합니다.

01 Skill 기반 시스템

02 지식 그래프

03 시맨틱 추론 레이어

04 Fast-Track 도입

MAKE DATA SMARTER, MAKE DECISIONS FASTER.




AI에게 모든 것을 맡기지 마세요 가장 잘하는 일에 집중시키면 됩니다.

필요한 것은 더 큰 모델이 아니라 다음 단계에 '꼭 필요한 것'만 정확히 건네는 설계입니다.


Andrej Karpathy가 말한 '컨텍스트 엔지니어링'의 핵심

무거운 MCP에서, 가볍고 효율적인 'Skill'로

Heavy: MCP



Light: Skill



더 단순한 구조 · 빠르고 정확 · 통제 · 검증 가능 - 그래서 흐름은 'Skill'로.

제품은, 계속 진화하고 있습니다

Function Calling·GenSQL 기반에 Skill 추론을 더해 더 깊게(고도화), 더 넓게(확장) 진화합니다.

질문 커버리지

정의된 질문(함수·SQL) > 정의 밖·복합·추론형 질문

업무 영역

매출 분석 > 재고·생산·주문·외부요인까지

작업 유형



현황 분석 > 탐색·Q&A·대시보드·자동화

사용자

분석가 중심 > 현업 사용자 주도(셀프서비스)

이를 떠받치는 검증·모니터링·로그·데이터 증강 역시 더욱 강화됩니다 ▲

SERVICE FLOW > 김대리의 하루 : 질문 하나가 업무 완결까지



사용자의 의도를 비즈니스 통찰로 변환하는 AI 데이터 생태계



전략적 하이브리드 LLM 아키텍처 - 보안과 성능의 유기적 최적화

보안성 · 성능 · 비용을 최적화하는 하이브리드(Hybrid) 운영 모델을 통해 사내 민감 데이터 격리와 고성능 추론 효율성을 동시 확보

ON-PREMISE TRACK

사내 GPU 기반 sLLM

민감 데이터 · 보안 최우선 프라이빗 분석

- ✓ Zero-Leakage: 독립 폐쇄망 구동으로 유출 차단
- ✓ Domain Optimization: 한국어 및 사내 특화 튜닝
- ✓ Asset Utilization: 사내 GPU 활용 고정비 운영



aisight Intelligent Router



판단 시점

LAYER 02(Model)의 Query Normalizer를 통한 정규화 직후(Pre-execution phase) 및 실제 데이터 조회 및 스킴 실행 전, 동적 경로를 확정합니다.



기준

- 보안 등급: PII 및 기밀 정보 스캔
- 연산 복잡도: sLLM vs CI. LLM 효율 분석
- SLA 임계치: 실시간성 및 비용 최적화 계산



기술 매커니즘

- Semantic Class.: 의도 벡터 매칭
- Policy Engine: RBAC 기반 판정
- Fallback: 마스킹 및 에스컬레이션

CLOUD TRACK

외부 상용 LLM (Claude/GPT)

최신 모델 기반 고난도 추론

- ✓ State-of-the-Art: 최신 모델 즉각 적용
- ✓ OpEx Optimized: 종량제 기반 비용 최적화
- ✓ Agility: 고난도 다단계 복합 추론 대응

멀티 LLM 프로바이더 생태계 | 업계 표준 8종 인프라 탑재

OpenAI

GPT 계열 추론

Anthropic

Claude 계열 분석

Gemini

멀티모달 최적화

vLLM

고속 추론 엔진

MLX

Apple 가속 지원

Ollama

독립 로컬 실행

LM Studio

모델 호스팅 서버

AI-Comp.

범용 규격 호환

기능별 엔드포인트 독립 분리

Text & Chart

질의응답 및 추론

Vision

시각 자료 인식

Audio

음성 인식·합성

Embedding

벡터 인덱싱

aisight 표준 내부 LLM Gemma 4 (31B)

- **Inference Optimization:** vLLM 가속 및 INT8/INT4 양자화 적용으로 대규모 배치 처리 보장
- **Skill set:** Function Calling 커스텀 튜닝을 통해 Skill Registry와 안정적 연동
- **Sovereign MLOps:** 보안 폐쇄망 내 경량 파인튜닝(QLoRA) 및 데이터 주권 기반 지식 업데이트

생각은 AI가, 실행은 스킬이 — '스킬(Skill)'은 AI가 현실의 데이터·시스템에 직접 닿아 실제로 실행하는 '손과 발'입니다. 에이전트의 프로세스는 사용자의 질문에 맞춰 단일 또는 다중 스킬을 자율적으로 선택하여 격리된 런타임 환경에서 업무를 완수합니다.

1. 스킬 정의 및 셋팅(Ops)

정의/제약

SLUG

스킬 명칭

Sales_

매출 데이터 분석가

System Prompt(스킬 기반 행동 핵심 지침)

```
# 당신은 [매출 데이터 분석 전문가]입니다.
'agent.ft_sales_ai' 테이블을 활용하여 주차별 통계를
분석합니다.
# 주요 지표 및 계산식
- 매출: SUM(sales_amt) / 주문건수:
COUNT(DISTINCT ord_id)
- AOV: 매출 / 주문건수 / 기준 주차: 'base_tw'

# 작업 순서 강제 (3-Step Loop)
1. db.list_tables로 테이블 구조 파악
2. db.describe_table로 컬럼 상세 확인
3. db.run_query로 SQL 실행 (읽기 전용)

# 답변 스타일 가이드
- 수치는 $ 표기 및 천 단위(,) 적용
```

연동 툴(Tool Binding)

- DB - Run SQL
- 웹 페이지 가져오기, 검색
- 질의 유효성 검색
- 데이터 탐색 질문 분리 프로세스

2. 메인 오케스트레이션

선택/조율

"지난 10주간의 매출 및 AOV 추이와 마케팅 성과를 분석해줘"

1 질문 이해(Parsing)

자연어 입력 전처리 및 NER(매출, 마케팅) 기반 의도 분류

2 스킬 선정 (Selection)

사용자 권한 내 최적 스킬셋 선정 프로세스



다중 스킬(Multi-Skill) 오케스트레이션:
[매출 분석가] + [마케팅 분석가] 병렬 호출 가능

3 스킬 실행 (Runtime)

선정된 스킬 전용 런타임 환경으로 이관

4 결과 통합 (Synthesis)

각 스킬 루프의 반환 데이터 정합성 검증

5 질문 이해(Parsing)

Markdown 규격 및 스타일 가이드 준수 답변

3. 스킬 내부 심층 실행

런타임 스킬 루프

3-1 정책 및 지침 로드

Ops에서 정의한 '매출 분석 전문가' 페르소나와 작업 순서 지침을 에이전트 런타임에 주입합니다.

3-2 자율 작업 계획

질문을 해결하기 위한 최적의 쿼리 시퀀스(매출/AOV 연산 플랜)를 수립합니다.

3-3 물리 작업 실행 (SQL/API or Tool)

바인딩된 툴을 통해 agent.ft_sales_ai 테이블에 직접 질의하거나 외부 API를 연동하여 데이터를 수집합니다.

3-4 중간 검증 (ReACT Loop)

인출된 데이터가 질문 해결에 충분하지 평가합니다.

ReACT 불충분 시 [3-2 작업 계획] 으로 피드백 루프

3-5 결과셋 반환 (Hand-off)

검증 완료된 데이터셋을 메인 흐름으로 안전하게 양도합니다.

aisight도 당연히 AI로 답합니다. 다만 “이 질문이 분석 가능한가”를 매번 AI에 묻지 않고, **검증된 지식**으로 먼저 확인한 뒤 **AI는 잘하는 일에** 집중시킵니다.

고객 관점

유효성까지 매번 AI에 맡길 때

aisight 지식 그래프로 먼저 검증할 때

용어 통일



부서·사람마다 다른 표현을 제각각 해석합니다

✓ 어떻게 부르든 같은 표준 용어로 통일합니다

지표 특징



비슷한 지표를 구분 못 해 임의로 골라 답합니다

✓ 유사한 지표가 여럿이면 정확한 지표로 특정합니다

모호함 해소



모호해도 일단 추측해서 답을 만듭니다

✓ 모호하면 사용자에게 되물어 명확히 유도합니다 (휴먼 루프)

AI의 역할



용어 해석·검증까지 AI가 전부 떠안습니다

✓ 검증은 지식 그래프가 맡고 AI는 분석에 집중합니다

기능 활용



매번 모든 기능을 동원해 비효율이 큼니다

✓ 질문 맥락을 이해해 필요한 기능만 호출합니다 (설계 중)

간단히 말하자면 대충 물어봐도 기준정보·지표를 표준으로 또렷하게 인식하고, 검증은 지식 그래프가 **분석은 AI가** 맡아 각자 잘하는 일에 집중합니다.

■ 복잡해지는 스킬에 그래프를 입히다

기준정보·지표·조건(라벨)과 각 항목의 표준 의미(노드), 그 사이의 연결 관계를 정교하게 설계해 둡니다.
이 지식 그래프가 촘촘할수록, 사용자가 어떻게 묻든 분석에 필요한 정확한 대상을 찾아냅니다.

KNOWLEDGE GRAPH VIEW

※ 그림은 이해를 돕기 위한 개념도입니다. 라벨·속성·관계의 상세 정의는 별도 설계 문서(온톨로지 스키마)로 일원화해 관리됩니다.



1 무엇을 묻는지 분류 (라벨)

질문 속 단어가 분석 기준인지·측정 지표인지·조건인지 종류를 먼저 가립니다.

2 정확한 의미로 특정 (노드)

"냉장고=REF"처럼 표준 용어로 바꿔 사용자가 찾는 정확한 대상을 집어냅니다.

3 연결을 따라 검증 (관계)

그 조합이 실제로 분석 가능한지 데이터 간 연결을 따라 확인합니다.

아래는 한 가지 예시입니다. 모호한 질문을 단계별로 되물어 **분석 가능한 의도로** 확정해 갑니다.

"2025년 유럽 A제품 매출 분석해줘"

제품을 해외 판매법인으로 판매하는 회사 기준

1 지역 > 법인 선택 '유럽'은 지역 — 어느 법인?

✓ 영국

스페인

독일

프랑스

2 매출 지표 특정 '매출' 중 어떤 지표? (복수 가능)

✓ GMV 총거래액

순매출

✓ Retail

Wholesale

3 제품 세부 조건 A제품은 어떤 구분?

✓ 빌트인

프리스탠딩

✓ 온라인 채널

오프라인 채널

이대로는 막연 — 무엇이 불명확?

- '유럽'은 지역일 뿐, 법인이 아님
- '매출'이 어떤 매출인지 불명확
- 제품 세부 조건 미지정

확정되는 의도 정의



기간

2025년



법인

영국 (UK)



지표

GMV · Retail



세부

빌트인 · 온라인 채널



입구에서 막히는 경우

미학습 지표·무관한 질문은 되물지 않고 '분석할 수 없습니다'로 차단

✓ CLEAR

최종 확정된 의도-분석 가능, 다음 단계로 전달

"2025년 영국 법인의 A제품 · 온라인 · 오프라인 , GMV · Retail 매출 분석" 으로 확정

■ 복잡해지는 스킬에 그래프를 입히다

Solution Deep Dive



전체 문장을 맥락별로 나눠 **그래프 DB가 파악한 맥락**에 맞춰 되물어 필요한 스킬만 골라 조합합니다.

한 문장에 여러 맥락이 섞여있는 사용자 질문

“지난달 영국 냉장고 매출·트래픽을 분석하고, 환율 영향도 찾아보고, 사내 전략문서도 정리해줘”

맥락 ① 데이터

▶ 해석된 질문 맥락

2026년 5월 영국 법인 냉장고의 매출·트래픽 데이터를 분석

그래프 DB가 지표 감지

✓ 매출

✓ 트래픽

✓ 어떤 형식으로 분석할까요?

현황분석 정형 보고서 톤

✓ 데이터탐색 데이터+짧은 인사이트

> 데이터탐색 Skill

맥락 ② 외부

▶ 해석된 질문 맥락

2026년 5월 기간의 국가 정세·환율 데이터를 외부에서 조회

외부 근거가 필요함

✓ 환율

✓ 시장이슈

✓ 어디서 근거를 가져올까요?

✓ 웹 검색 그라운드링 범용 웹·뉴스 탐색

지정 포털·소스 신뢰 소스 한정

> Grounding Skill

맥락 ③ 사내문서

▶ 해석된 질문 맥락

관련 사내 전략·정책 문서 내용 확인이 필요

사내 지식이 필요함

✓ 전략문서

✓ 어떤 문서에서 찾을까요?

✓ 전략·기획 문서 제안서·기획안

회의록·일보·규정 운영 기록 전반

> Document Skill

선택된 스킬을 조합해 하나의 답변으로 - 데이터탐색 + Grounding + Document

맥락에 꼭 필요한 스킬만 불러 비용·속도·정확도를 동시에 최적화합니다.

■ 예상 밖의 질문도 케이스로 등록하고, 채점으로 검증합니다

Solution Deep Dive



정해진 케이스에 없는 질문이 와도 멈추지 않습니다. **추측 대신** 의도를 확인하고 > 가장 가까운 분석 유형을 추천·보정하고 > 케이스로 등록합니다.

확정된 케이스가 곧 답안지가 됩니다. 모델을 다시 학습시키는 것이 아니라, 채점과 보정으로 답을 검증합니다.

PHASE 01

케이스 확장

질문 > 케이스

1

감지

기존 케이스·패턴과 매칭이 약한
질문 인식
분류 밖 규

2

확인 · 되물음

추측 대신 의도를 되물어 명확화
휴먼루프

3

추천 · 보정

가장 가까운 지표·유형을 AI
제안 > 사람 확정
사람 검수

4

케이스 등록

준비단계(마트·지표·연산·그래프
)가 다 채워진 뒤에만 반영
미보유 > 백로그

PHASE 02

답안 검증

케이스 > 답안지 > 채점

5

답안지 자동 생성

확정된 케이스가 그대로
표준 답안지가 됩니다

6

채점 · 재검증

정확도와 함께 5회 반복 응답의 일관성까지
측정합니다

7

원인 추적 · 보정

점수만 고치지 않고 오답의 원인 단계를
찾아 바로 잡습니다.

🔄 그래프나 분석 규칙이 바뀌면 영향받는 케이스만 자동 재채점. 케이스는 고정이지 않음. 검증 거쳐 확장됩니다.

■ 담당자 화면으로 확인하는 케이스 확장 and 답안 검증

Solution Deep Dive



품질 담당자는 이 화면에서 AI가 수행한 확장 and 검증 과정을 직접 확인합니다.

왼쪽은 예상 밖 질문을 진단해 케이스로 등록하는 화면, 오른쪽은 답안을 채점하고 원인을 보정하는 화면입니다.

① 케이스 확장 · 예상 밖 질문 진단

RESULT 추측 + 준비단계

질문 · 제품별 재고화전율이 어떻게 돼?

AI 추측 · 어떻게 풀릴까

미지 지표 — 마트·지표 정의 필요

준비단계 · 마트 → 지표 → 연산 → 조회 → 그래프

✗ 마트 (테이블) 신규 마트 생성 필요

✗ 지표 정의 지표 정의 필요

✓ 연산 설정 기존 연산자로 충족

✓ 조회 조건 기존 차원·필터로 충족

✗ 그래프 관계 관계 엣지 추가 필요

아직 미학습 영역 — 부족한 단(X)을 먼저 채워야 해요. 마트·지표가 만들어지고 그래프에 반영되면 플레이 북이 자동 갱신됩니다.

파이프라인 채움 (데모)

미학습으로 표시

화면 목업 · 추측 진단 and 준비단계 확인 (개발 예정)

② 답안 검증 · 채점 and 원인 보정

파싱 일관성 · 평균
4.3 / 5회

필수 통과율
75 %

선택 부분점수 · 평균
0.63 / 1.0

케이스 · 온도차 변형으로 재검

파싱 일관성 (N=5)

구조 재검 (승2+승3)

제품별로 누가 주문건수 하락에 기여했나?
매출분석

일관 5/5

필수 통과 · 선택 2/2

제품별로 누가 매출 하락에 기여했나?
매출분석

온도차 4/5

필수 통과 · 선택 1/2

경쟁사 대비 우리 냉장고 매출 위치는?
마켓센싱

일관 5/5

필수 통과 · 선택 2/2

브라질 냉장고 매출 전년 대비 왜 빠졌고 경쟁사 ...
매출분석
클릭 — 귀속 필요

불만감 3/5

필수 미달 → 0점

필수 미달 · 귀속(triage) — 점수 수정 버튼은 없어요. 원천(코드/케이스/그래프/명세)을 고르고, 고친 뒤 재채점합니다.

✓ 노트① 원인분석 · 진입=매출(GMV) — 통과

X 노트② 경쟁비교 · 진입 재지정=경쟁사매출(VPM) — 필수 미달

승2 · 엣지 · 합조 (금지형)

자사·시장 수치 직접 비교/차이 계산 금지 · 측정계 상이 명시

실제 답변: "GMV -12%, 시장 -8% — 격차 4%p" ← 측정계 다른 두 수치를 직접 차감 (위 반!)

① 답변(린타임) 오류

② 라우팅·분배 정답 오류

③ 그래프·레시피 원인

④ 명세가 과함

화면 목업 · 채점 and 재검증 (개발 예정 · 숫자는 예시)

채점 and 보정이 쌓일수록 AI 답변의 정확도는 스스로 정교해집니다.

■ 정확도의 마지막 10%는 모델이 아니라 구조가 채웁니다

Solution Deep Dive



최신 모델은 Text-to-SQL만으로도 약 90%에 도달합니다. 문제는 남은 10%입니다.
검증된 시맨틱 추론 레이어가 있어야 그럴듯하지만 틀린 숫자를 걸러낼 수 있습니다.

LLM > DB 직접 (Text-to-SQL)

약 90%

최신 모델로 도달 가능한 수준. 다만 틀려도 그럴듯한 숫자를 반환합니다

>

+ 시맨틱 추론 레이어 경유

98% 이상

범위 밖이면 '답할 수 없음'으로 거절해 틀린 숫자를 내지 않습니다

출처: dbt Labs 벤치마크 재실행(2026. 4) · 동일 데이터셋 ACME Insurance(data.world) · 동일 모델 Sonnet 4.6 / GPT-5.3 Codex · 오픈소스로 재현 가능

같은 방향

구글 데이터 에이전트 · 스노우플레이크 Cortex · 데이터브릭스 Genie 등 모두 LLM 아래에 시맨틱 추론 레이어를 둡니다

모델 성능은 갈수록 평준화됩니다. 차이는 그 아래의 기반 구조에서 만들어집니다.

aisight · SRL은 검증된 데이터 경로 위에 '왜'를 묻는 추론 구조를 더해, 같은 질문은 언제나 같은 경로로 답합니다.


■ 실제 구현 사례 예시



① 질문 의도에 맞는 지표 확인



③ 답변 생성 · 인사이트와 시각화



② 세부 조건 선택과 되물음



④ 검증된 조회 경로 상세

■ 흠어진 문서를 하나의 지식으로 엮다 : Knowledge Wiki

Solution Deep Dive



5단계 파이프라인으로 수집된 사내 문서를 Wiki 자산화 스토리지(wiki_pages & wiki_embed)에 물리적으로 격리해 적재하고, 시맨틱 레이어와 연동하여 실시간 비즈니스 질의 활용성을 극대화합니다.

1. Wiki Ingest 파이프라인

01 원천 파일 업로드 (Intake)
규정, 제안서, 보고서, 일보 등 파편 수집

02 멀티 파서 구동 (Conversion)
Java / Python 독립 파서 기반 무결성 변환

03 LLM 정제 루프 (Ingest Loop)
5단계 시스템 프롬프트 기반 맥락 정제

04 하이브리드 인덱싱 (Indexing)
마크다운 구조화 및 시맨틱 벡터 생성

05 관계 매핑 (Relation Engine)
자동 카테고리 분류 및 링크 구조화

2. WIKI 자산화 스토리지 (STORAGE HUB)



벡터 DB 통합 지식 저장소 (PG Vector Integrated DB)

정제된 마크다운(Markdown) 문서 자산을 고속 시맨틱 검색용 고차원 벡터 데이터로 인덱싱하여 Vector DB 레이어에 통합 적재 및 실시간 활용

3. SEMANTIC UTILIZATION (활용 단계)

🔍 의미 기반 하이브리드 검색

현업 용어(Jargon)나 모호한 질문 입력 시, 키워드(BM25)와 의미 벡터 분석을 결합해 질문자의 진짜 숨은 의도를 파악하여 관련 자산을 정밀 탐색합니다.

🗨️ 근거 기반 추론 접지

인출된 위키 내 자동 연결된 [[wikilink]] 관계망을 역추적하여 답변을 도출합니다. 명확한 사실(Fact)과 본문 출처(Citation)를 표기하여 AI 환각을 완벽히 격리합니다.

Q. "취업규칙상 연차 보상 기준이랑 지난주 보고된 정산 현황 확인해줘"

A. "[[사내_취업규칙_제12조]]에 의거... 또한 [[주간보고_재무팀_W21]]에 따르면 현재..." [출처 매핑 완료]



Vendor 분리형 Fail-soft 엔지니어링 설계 기반의 무중단 운영 보장

각 문서 변환기는 독립 프로세스로 격리 구동됩니다. 사내 보고서나 제안서 파싱 중 특정 결합이 발생하더라도, 전체 위키 서버는 중단 없이 가용 포맷 자산에 한해 무중단 질의 서비스를 보장합니다.

기업 내 방치된 정성·정량, 정형·비정형 문서(PDF, 엑셀 등)를 AI가 스스로 읽고 해석하여 데이터로 자동 마이그레이션합니다. 단순 텍스트 추출을 넘어 다단 레이아웃, 복잡한 표(Table) 구조의 맥락까지 파싱하는 '완전 자동화 지식 자산화'를 구현합니다.



멀티 포맷 데이터 인입

텍스트, 도형, 표가 혼재된 비정형 문서 및 정량적 엑셀 데이터를 포맷의 제약 없이 일괄 수집합니다.



지능형 구조 분석 (Parsing)

다중 레이아웃 등 구조를 완벽히 식별하여 원본 데이터의 문서 및 흐름, 맥락을 정확히 추출합니다.



마크다운(MD) 최적화 변환

추출된 데이터를 LLM이 가장 잘 이해하는 마크다운 규격으로 자동 변환하고, 최적의 시맨틱 단위로 분할(Chunking)합니다.



지식 DB 자동 마이그레이션

가공 완료된 정성/정량 데이터를 사내 지식 위키 및 Vector DB로 영구 보관하여 즉시 검색 가능한 자산으로 편입시킵니다.

aisight Document Parser Core Engine

정성·정량 데이터 통합 마이그레이션

내부 문서 및 외부 문서 업로드 즉시 파싱 파이프라인으로 이관하여 지식 관계 구조화

표/이미지 맥락 이해 (Vision)

단순 Parser를 넘어, 표의 헤더와 본문 관계, 이미지 내 객체의 의미까지 파악하여 데이터의 손실을 방지합니다.

메타데이터 자동 추출 및 태깅

문서 내 핵심 엔티티(부서명, 날짜, 제품명 등)를 자동 식별하여 검색 효율성을 극대화하는 태그를 부여합니다.

무인(Human-less) 파이프라인


문서 업로드 즉시 파싱-청킹-임베딩-적재까지 사람의 개입 없이 완전 자동화된 백엔드 프로세스로 작동합니다.



문서'를 '살아있는 AI 데이터 베이스'로 실시간 마이그레이션

단순 문서 저장을 넘어 사내 각 종 문서를 통합·적재하고, '문서 위키화'·'지식 관계망 형성'·'태그 기반 연관 탐색'으로 이어지는 답변 제공 플로우를 구현합니다.

전사 통합 데이터 구축(EDW) 등 무거운 IT 프로젝트를 기다릴 필요가 없습니다. 기존에 가장 활발히 사용 중인 핵심 대시보드 2~3개와 단일 부서를 대상으로, 단 6주 만에 확실한 도입 성과(Quick Win)를 증명합니다.



⚠ 초기 AI 도입의 장벽

- AI 도입을 위해 전사 데이터 통합(EDW)부터 끝내야 한다는 부담
- 전사 확산을 목표로 진행하다 길어지는 PoC와 흐려지는 성과
- 사내 민감 데이터를 외부 상용 API에 노출하는 보안 리스크
- 사용량에 따라 예측·통제가 어려운 토큰 및 인프라 비용



🚀 aisight Fast-Track 도입

- 데이터 이관 없이, 검증된 사내 대시보드를 그대로 연결
- 핵심 대시보드 2~3개·단일 부서로 6주 내 성과 증명
- 민감 데이터는 사내 sLLM에서 처리, 외부 API는 일반 작업에 한정 (Hybrid 라우팅)
- 작업 복잡도에 따라 LLM을 동적 분배하여 비용 최적화

감사합니다. 궁금한 점을 남겨 주세요.

설계 상세와 검증 방식은 요청하시면 별도 자료로 정리해 드립니다.
고객사 데이터 기준으로 정확도를 직접 확인해 보시는 것도 가능합니다.

Q & A

궁금하신 점은 편하게 질문해 주세요

Homepage

www.sailingstone.io

Next Step

정확도 검증 · 고객사 데이터로 직접 확인

MAKE DATA SMARTER, MAKE DECISIONS FASTER.

